SpectraAI: Prospecção de Terras Raras a partir de Imagens Multiespectrais ASTER com Aprendizado de Máquina e Visão Computacional

Drielly S. Farias[1], Eduardo F. Rizk[1], Giovanna F. B. Vieira[1], Larissa M. P. S. Souza[1], Lucas R. Jorge[1], Mateus B. Pereira[1], Pedro A. B. Martins[1]

[1]Instituto de Tecnologia e Liderança (Inteli)
Av. Prof. Almeida Prado, 520 – Butantã – 05508-901 – São Paulo – SP

{drielly.farias,eduardo.rizk,larissa.souza,giovanna.vieira, lucas.jorge,mateus.pereira,pedro.martins}@sou.inteli.edu.br

Abstract. *This work presents SpectraAI, a reproducible geospatial pipeline that transforms ASTER multispectral imagery into probabilistic indicators of rare earth element (REE) prospectivity. The methodology includes atmospheric filtering, spectral feature engineering, and construction of labeled 128x128x9 image chips. A comparative evaluation using MLP, CNN, and transfer learning with MobileNetV2 shows consistent improvement, with the final model achieving 88.14% accuracy, 0.8511 F1-score, and 0.9167 ROC-AUC. Grad-CAM analysis indicates alignment with geologically relevant patterns.*
Keywords: *remote sensing, ASTER, rare earth elements, deep learning, mineral prospecting.*

Resumo. *Este trabalho apresenta o SpectraAI, um pipeline reprodutível que transforma imagens multiespectrais ASTER em indicadores probabilísticos de potencial prospectivo de elementos de terras raras (REE). A metodologia inclui filtragem atmosférica, engenharia de atributos espectrais e construção de chips 128x128x9 rotulados. A avaliação comparativa entre MLP, CNN e transfer learning com MobileNetV2 demonstra melhoria consistente, com o modelo final alcançando 88,14% de acurácia, F1-score de 0,8511 e ROC-AUC de 0,9167.*
Palavras-chave: *sensoriamento remoto, ASTER, elementos de terras raras, aprendizado profundo, prospecção mineral.*

1. Introdução

Os Elementos de Terras Raras (Rare Earth Elements — REE) compõem um grupo de 17 elementos amplamente empregados em tecnologias de alto valor agregado, incluindo eletrônica, aplicações industriais avançadas e sistemas energéticos de baixo carbono. A demanda crescente por esses elementos, impulsionada pela transição energética global, tem intensificado preocupações quanto à segurança de suprimento, dado que a produção e o refino permanecem geograficamente concentrados [International Energy Agency 2021, United States Geological Survey 2025]. Nesse cenário, o Brasil ocupa posição estratégica em virtude de suas reservas expressivas de ETR, o que reforça a relevância de métodos eficientes e escaláveis de prospecção mineral. Do ponto de vista operacional, a prospecção mineral tradicional depende de campanhas de campo, amostragem e análises laboratoriais, etapas onerosas e de difícil escalabilidade espacial. Em contrapartida, o sensoriamento remoto oferece um meio de observação sistemática e repetível para apoiar a triagem de alvos, especialmente quando combinado a métodos quantitativos de análise de dados

[Sabins 1999, van der Meer et al. 2012].

Nesse contexto, o Advanced Spaceborne Thermal Emission and Reflection Radiometer (ASTER) consolidou-se como um dos sensores mais utilizados em mapeamento litológico e exploração mineral, ao disponibilizar bandas espectrais relevantes no VNIR e no SWIR [Abrams and Yamaguchi 2019, Ramsey and Flynn 2020]. Contudo, a interpretação manual dessas cenas permanece limitada pela alta dimensionalidade espectral e pela sutileza de padrões associados a mineralizações [Shirmard et al. 2022]. Historicamente, as aplicações de aprendizado de máquina nesse domínio têm sido conduzidas a partir de representações tabulares, descartando a estrutura espacial das imagens. Diante dessa limitação, redes neurais convolucionais (CNN) permitem aprender padrões espaciais e espectrais diretamente a partir de janelas de imagem, preservando relações de vizinhança entre pixels [Zhu et al. 2017].

Este trabalho apresenta o SpectraAI, um pipeline de ciência de dados geoespaciais que utiliza imagens ASTER e dados de referência fornecidos pela Frontera Minerals para avaliar modelos de aprendizado de máquina e visão computacional na estimativa probabilística do potencial prospectivo de REE. O objetivo geral é desenvolver e avaliar um modelo de deep learning capaz de analisar imagens multiespectrais ASTER e produzir um ranking de prospectividade mineral que subsidie a priorização de áreas para campanhas de pesquisa geológica de campo. As principais contribuições incluem: a construção de um pipeline reprodutível end-to-end; a comparação sistemática entre modelos tabulares (MLP), CNN e transfer learning com MobileNetV2 [Sandler et al. 2018]; e a análise de interpretabilidade via Grad-CAM.

Especificamente, o trabalho visa:

- **Construir protocolo de engenharia de atributos espectrais** para realce de minerais de alteração hidrotermal a partir de bandas ASTER;
- **Comparar arquiteturas de visão computacional** (CNN) com baselines clássicos (SVM, RF, Regressão Logística) e tabular (MLP);
- **Implementar validação estratificada** com métricas robustas ao desbalanceamento (F1-score, acurácia balanceada, ROC-AUC);
- **Produzir ranking probabilístico** de áreas prospectivas como ferramenta de apoio à decisão em exploração geológica.

2. Fundamentação Teórica

A análise por sensoriamento remoto em geociências fundamenta-se na interação entre radiação eletromagnética e materiais geológicos, em que minerais e rochas exibem respostas espectrais condicionadas por composição e estrutura físico-química. Técnicas clássicas incluem razões de bandas e Análise de Componentes Principais (PCA), frequentemente empregadas para realçar assinaturas diagnósticas de minerais de alteração e discriminar unidades litológicas [Abrams and Yamaguchi 2019, Rowan and Mars 2003]. O sensor ASTER, projetado com subsistemas em VNIR (3 canais, 15 m) e SWIR (6 canais, 30 m), favorece a investigação de características mineralógicas relevantes, tendo contribuído significativamente para mapeamento litológico e exploração mineral ao longo de décadas [Abrams and Yamaguchi 2019, Ramsey and Flynn 2020].

Nos últimos anos, a integração de

aprendizado de máquina ampliou o escopo do sensoriamento remoto aplicado à exploração mineral, ao permitir modelar relações não lineares e reduzir a dependência de regras fixas. Pipelines supervisionados capazes de transformar atributos espectrais em classificações quantitativas têm sido propostos, comparando algoritmos clássicos e redes neurais sob métricas objetivas [Bahrami et al. 2024]. Em paralelo, revisões sobre *mineral prospectivity mapping* com *deep learning* indicam crescimento do uso de modelos profundos, mas também ressaltam desafios como qualidade e escassez de rótulos, desbalanceamento de classes e robustez na generalização espacial (SUN et al., 2024; SHIRMARD et al., 2022).

3. Materiais e Métodos

3.1. Materiais

Os materiais utilizados reúnem dados orbitais, dados de referência geográfica e metadados de rotulagem fornecidos pela Frontera Minerals. A base orbital é composta por cenas ASTER do produto L2 Surface Reflectance VNIR and Crosstalk-Corrected SWIR (AST_07XT) [NASA], com janela temporal entre 2000 e 2007 para preservar a disponibilidade operacional das bandas SWIR. Foram priorizadas as bandas VNIR (B01, B02, B03N) e SWIR (B04-B09), totalizando nove bandas por chip. As cenas candidatas são recuperadas por caixa geográfica ao redor dos pontos-alvo, com seleção por menor cobertura de nuvens. O material de referência para supervisão é composto por coordenadas georreferenciadas de interesse geológico e listas de códigos positivos e negativos. Após remoção de amostras com rótulos inválidos, o dataset final contém 295 chips multiespectrais, dos quais 179 pertencem à classe negativa (60,7%) e 116 à classe positiva (39,3%).

3.2. Métodos

3.2.1. Aquisição e Pré-processamento

A base de dados é composta por amostras de solo e rocha coletadas *in situ* pela Frontera Minerals, rotuladas binariamente: classe positiva (áreas com teores acima do *cut-off* econômico) e classe negativa (áreas estéreis ou com teores de base). As assinaturas espectrais foram extraídas de imagens ASTER, priorizando cenas históricas (2000-2007) com cobertura de nuvens inferior a 20% [NASA]. O pré-processamento incluiu filtragem de máscaras (remoção de pixels contaminados por nuvens e vegetação densa), reprojeção para WGS84, cálculo de índices minerais baseados em razões de bandas e vetorização para a fase inicial de baselines. O dataset é construído a partir de chips gerados ao redor de pontos georreferenciados, sendo cada chip um GeoTIFF multibanda (128×128×9) com bandas VNIR+SWIR alinhadas. A extração utiliza *bounding box* com jitter controlado por semente, garantindo variação posicional do ponto de referência dentro do chip.

3.2.2. Modelagem

O desempenho de referência foi estabelecido por algoritmos clássicos (SVM, Random Forest, Regressão Logística) otimizados via *GridSearchCV* e por uma rede neural densa (MLP) como baseline de deep learning sobre dados vetorizados. Visando superar a limitação da MLP, que ignora a vizinhança espacial, o projeto evoluiu para redes neurais convolucionais (CNN), que recebem o chip em sua forma original (Altura x Largura x Canais), permitindo que filtros convolucionais identifiquem texturas e padrões morfológicos. A arquitetura baseline é composta por dois blocos convolucionais (Conv2D com ReLU, regularização L2 e MaxPooling2D) seguidos por camadas densas de classificação

com ativação sigmoid. Para investigar o impacto de escolhas arquiteturais, foram definidas seis configurações em estudo de ablação, variando taxas de dropout, learning rate, profundidade da rede e resolução de entrada.

3.2.3. Protocolo Experimental

O conjunto de dados foi dividido em treinamento (70%), validação (15%) e teste (15%), utilizando amostragem estratificada em duas etapas com a função *train_test_split* do scikit-learn. Essa divisão assegura que a proporção entre classes seja preservada em todos os subconjuntos. A normalização é realizada por padronização z-score por canal espectral, cujos parâmetros são estimados exclusivamente a partir do conjunto de treinamento e aplicados aos conjuntos de validação e teste, evitando vazamento de informação estatística. O conjunto de validação monitora o desempenho ao longo das épocas e identifica sinais de sobreajuste, enquanto o conjunto de teste permanece isolado até a avaliação final. O desempenho é avaliado por F1-score, acurácia balanceada e ROC-AUC, métricas adequadas para cenários com desbalanceamento de classes. Data augmentation (RandomFlip, RandomRotation e RandomContrast) é aplicada exclusivamente ao conjunto de treinamento.

3.2.4. Transfer Learning

Reconhecendo o tamanho limitado do dataset (N=295), o pipeline incorporou transfer learning com o backbone MobileNetV2 [Sandler et al. 2018], pré-treinado em ImageNet. Para compatibilizar as 9 bandas ASTER com os 3 canais esperados pelo modelo, uma camada de convolução 1×1 realiza combinação linear das bandas para projeção em espaço latente de 3 canais, preservando a riqueza espectral com apenas ˜30 parâmetros adicionais. O treinamento ocorre em duas fases: na primeira (head training, 4 épocas), o backbone permanece congelado e apenas a camada adaptadora e a cabeça de classificação são treinadas; na segunda (fine-tuning parcial, 8 épocas), as últimas 20 camadas do MobileNetV2 são desbloqueadas (exceto BatchNormalization). Grid search sobre learning rates {1e-4, 1e-5} e batch sizes {8, 32} identificou a configuração ótima (LR=1e-4, BS=8).

4. Trabalhos Relacionados

A revisão de [Abrams and Yamaguchi 2019] documenta duas décadas de contribuições do sensor ASTER para mapeamento litológico e exploração mineral, consolidando práticas de razões de bandas e PCA. [Rowan and Mars 2003] demonstraram a capacidade das bandas ASTER em distinguir litologias e mapear zonas de contato metamórfico associadas a REE em Mountain Pass (Califórnia), confirmando a viabilidade dos dados multiespectrais para caracterização mineral.

[Bahrami et al. 2024] compararam RF, SVM, XGBoost e ANN para mapeamento litológico automatizado com ASTER, evidenciando que escolhas de pré-processamento afetam a qualidade dos mapas, porém o estudo foca em classes litológicas regionais e não em ranking prospectivo binário. [Luo et al. 2025] propuseram o framework DEEP-SEAM v1.0 com Deviation Networks para prospecção semi-supervisionada em dados multifonte, sem utilizar sensoriamento remoto multiespectral nativo. [Song et al. 2024] aplicaram redes multitarefa a dados geoquímicos tabulares para predição de REE, sem explorar informação de imagem. [Chen et al. 2014] foram pioneiros em aplicar deep learning a dados hiperespectrais de sensoriamento remoto com patches espaciais, abordagem análoga à estratégia de chips do SpectraAI, mas

voltada a uso do solo.

Em revisão abrangente, [Shirmard et al. 2022] identificam que poucos estudos realizam comparações sistemáticas entre representações tabulares e espaciais sobre o mesmo dataset e com as mesmas métricas. O SpectraAI diferencia-se ao integrar, em um pipeline unificado e reprodutível, a comparação direta entre modelos tabulares (MLP), CNN e transfer learning com MobileNetV2 sobre dados multiespectrais ASTER, voltado especificamente para prospecção de REE com geração de ranking probabilístico de áreas.

5. Resultados e Discussão

5.1. Comparação de Desempenho

A avaliação sistemática do pipeline proposto abrangeu três arquiteturas complementares: modelos tabulares supervisionados referenciados por uma rede neural densa (MLP), redes neurais convolucionais (CNN) treinadas do zero e transfer learning com MobileNetV2 pré-treinada. A comparação foi conduzida sob condições experimentais idênticas, utilizando o mesmo dataset (N=295, 70% treinamento, 15% validação, 15% teste estratificado) e métricas robustas ao desbalanceamento de classes. O modelo MLP, operando sobre representação tabular com PCA em 2 componentes, alcançou acurácia de 79,66% e F1-score de 0,7391, estabelecendo o piso de referência. O desempenho limitado reflete a perda de informação espacial decorrente da compressão por PCA, que impede a captura de padrões morfológicos e contextuais associados a mineralizações.

A CNN baseline, ao preservar a estrutura espacial dos chips (128×128×9), elevou o desempenho para 82,44% de acurácia e ROC-AUC de 0,9011 na melhor configuração de ablação (64×64), confirmando que a informação espacial é relevante para o problema. O estudo de ablação identificou que a redução de resolução de entrada melhorou a generalização ao reduzir dimensionalidade enquanto preserva informação discriminativa, e que a remoção de camadas convolucionais causa colapso em ROC-AUC, confirmando a essencialidade da extração automática de características espaciais. O transfer learning com MobileNetV2, aproveitando representações pré-aprendidas em ImageNet com adaptação espectral via convolução 1×1, alcançou resultados superiores em todas as métricas: acurácia de 84,75%, F1-score de 0,8085 e ROC-AUC de 0,9312, com convergência em apenas 12 épocas e redução de 72% em parâmetros treináveis em relação à CNN simples. A evolução progressiva de desempenho é sintetizada a seguir: o MLP baseline (A03) alcançou 79,66% de acurácia, F1-score de 0,7391 e ROC-AUC de 0,8575, com 6 FP e 6 FN; a CNN com ablação (A06, 64×64) elevou para 82,44%, F1 de 0,7878 e ROC-AUC de 0,9011; o transfer learning via grid search (A08) atingiu 84,75%, F1 de 0,8085 e ROC-AUC de 0,9312, com 5 FP e 4 FN; e o pipeline final reprodutível (A11) consolidou o melhor resultado global com 88,14% de acurácia, F1 de 0,8511 e ROC-AUC de 0,9167, com apenas 4 FP e 3 FN.

5.2. Modelo Final (Pipeline A11)

O pipeline final (A11) foi executado de forma integrada e reprodutível (seed=42), com treinamento em duas fases do MobileNetV2 adaptado espectralmente, sobre o dataset completo de 295 chips multiespectrais ASTER (177 treino, 59 validação, 59 teste). O modelo final alcançou o melhor desempenho global: acurácia de 88,14%, precisão de 83,33%,

recall de 86,96%, F1-score de 0,8511, acurácia balanceada de 87,92%, ROC-AUC de 0,9167 e PR-AUC de 0,8588, em 13 épocas totais (6 head + 7 fine-tuning) e 94,4 s de treinamento. A Tabela 1 detalha essas métricas.

Tabela 1. Métricas do modelo final (A11) no conjunto de teste. Fonte: Autores (2026)

Métrica	Valor
Acurácia	88,14%
Precisão	83,33%
Recall (Sensibilidade)	86,96%
F1-score	0,8511
Acurácia Balanceada	87,92%
ROC-AUC	0,9167
PR-AUC	0,8588
Épocas totais	13 (6 head + 7 fine-tuning)
Tempo de treinamento	94,4 s

A Figura 1 apresenta a matriz de confusão do modelo final no conjunto de teste (n=59). O modelo classificou corretamente 52 das 59 amostras (88,14%), com TN=32, FP=4, FN=3 e TP=20. A redução de falsos positivos (de 5 para 4) e falsos negativos (de 4 para 3) em relação ao A08 confirma a melhoria de generalização do pipeline consolidado. O recall de 86,96% indica que o modelo detecta a grande maioria das áreas com potencial de REE, enquanto a precisão de 83,33% assegura que a maioria das áreas sinalizadas corresponde a regiões de interesse geológico. A Figura 2 apresenta as curvas ROC (AUC=0,92) e Precision-Recall (AP=0,86), demonstrando capacidade discriminativa robusta em diferentes limiares de decisão e manutenção de alta precisão mesmo em regimes de alto recall. Do ponto de vista operacional, os escores probabilísticos produzidos pelo modelo permitem ordenar as áreas analisadas em um ranking contínuo de prospectividade, no qual regiões com maior probabilidade de presença de REE são priorizadas para investigação de campo, constituindo o produto final do pipeline como ferramenta de apoio à decisão em exploração mineral.

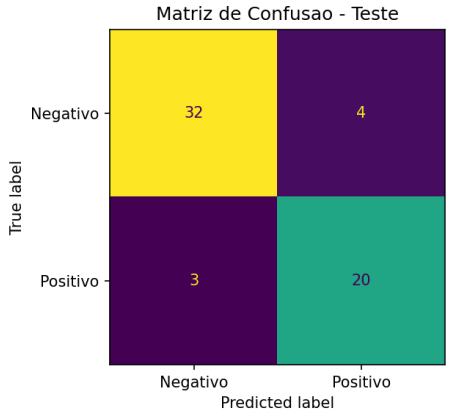

Figura 1. Matriz de Confusão do Modelo Final (A11) — Conjunto de Teste. Fonte: Autores (2026)

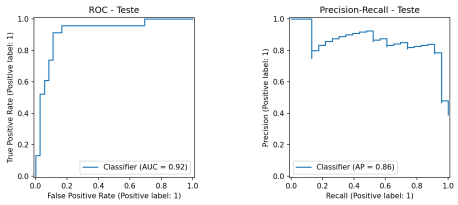

Figura 2. Curvas ROC e Precision-Recall do Modelo Final (A11). Fonte: Autores (2026)

5.3. Interpretabilidade via Grad-CAM

A Figura 3 apresenta mapas de ativação Grad-CAM que visualizam quais regiões espaciais o modelo MobileNetV2 prioriza ao fazer predições. A visualização sobrepõe os mapas de calor a um chip ASTER em falsa cor de uma amostra da classe positiva, comparando as ativações para as predições de cada classe. O mapa da classe positiva (real) revela ativações concentradas em transições espectrais coerentes e bordas espaciais pronunciadas, enquanto o mapa da classe negativa apresenta padrão mais disperso e difuso. Essa concentração alinha-se com o conhecimento geológico de que bandas SWIR são sensíveis a óxidos e argilas associados a REE, e que limites de alteração constituem estruturas espaciais informativas. A diferença de padrão entre as predições de classes positiva e negativa sugere que a rede responde a combinações espaciais e espectrais relevantes, conferindo transparência às predições e faci-

litando a auditoria por especialistas de domínio.

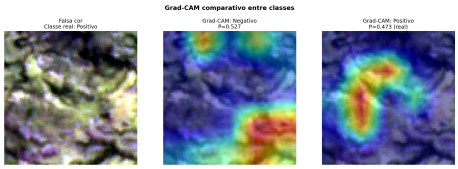

Figura 3. Mapas Grad-CAM do Modelo Final — Comparação entre Classes. Fonte: Autores (2026)

5.4. Discussão

A superioridade do transfer learning valida a hipótese de que informação espacial via CNN, combinada com representações pré-aprendidas (ImageNet), oferece vantagens significativas para identificação de padrões associados a REE. O estudo de ablação reforça essa conclusão: regularização L2 e dropout controlam a complexidade do modelo, enquanto a remoção de camadas convolucionais causa colapso em ROC-AUC. Apesar dos resultados encorajadores, o dataset de 295 amostras situa-se no limiar inferior de viabilidade para deep learning, e a validação utilizou rótulos de referência sem confirmação de campo. Ainda assim, o pipeline demonstra o potencial do aprendizado profundo aplicado a sensoriamento remoto como ferramenta de apoio à prospecção mineral.

6. Conclusão

Este trabalho apresentou o SpectraAI, um pipeline reprodutível de ciência de dados geoespaciais para prospecção de REE a partir de imagens ASTER, cujo produto final é um ranking probabilístico de áreas por potencial prospectivo. Os experimentos demonstraram progressão consistente de desempenho — do MLP (79,66%) à CNN (82,44%) ao pipeline final A11 com transfer learning (88,14% de acurácia, F1=0,8511, ROC-AUC=0,9167), com apenas 4 FP e 3 FN em 59 amostras de teste.

6.1. Principais Contribuições

As contribuições do trabalho são: **(i)** a construção de um pipeline reprodutível end-to-end, desde a aquisição de cenas ASTER até a exportação de predições, com controle de seed e separação rigorosa entre conjuntos de dados; **(ii)** a comparação sistemática e controlada entre MLP, CNN e transfer learning sob métricas robustas ao desbalanceamento; **(iii)** a demonstração de que transfer learning com adaptação espectral via convolução 1×1 é viável e eficaz com poucos dados rotulados (N=295); e **(iv)** a análise de interpretabilidade via Grad-CAM, que revelou alinhamento entre regiões ativadas e características espectrais geologicamente relevantes, conferindo transparência às predições. Do ponto de vista prático, o ranking probabilístico de áreas produzido pelo pipeline representa uma ferramenta concreta de apoio à decisão em exploração mineral, capaz de reduzir custos operacionais ao direcionar esforços de campo para regiões com maior probabilidade de ocorrência de REE.

6.2. Limitações e Trabalhos Futuros

Limitações relevantes incluem: o dataset de 295 amostras situa-se no limiar inferior de viabilidade para deep learning; os rótulos derivam de referência geológica sem validação de campo; e a amostragem estratificada aleatória não garante generalização espacial. Como direções futuras, destacam-se validação geológica in situ, validação cruzada espacial, integração multissensor (Landsat-8, Sentinel-2) e investigação de arquiteturas avançadas (ResNet, Transformers).

Referências

Abrams, M. and Yamaguchi, Y. (2019). Twenty years of ASTER contributi-

ons to lithologic mapping and mineral exploration. *Remote Sensing*, 11(11):1394.

Bahrami, H. et al. (2024). Machine learning-based lithological mapping from ASTER remote-sensing imagery. *Minerals*, 14(2):202.

Chen, Y. et al. (2014). Deep learning-based classification of hyperspectral data. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 7(6):2094–2107.

International Energy Agency (2021). The role of critical minerals in clean energy transitions. Technical report, IEA, Paris.

Luo, Z. et al. (2025). An explainable semi-supervised deep learning framework for mineral prospectivity mapping: DEEP-SEAM v1.0. *EGUsphere (preprint)*.

NASA. ASTER L2 surface reflectance VNIR and crosstalk-corrected SWIR (AST_07XT). NASA Earthdata. Acesso em: 26 fev. 2026.

Ramsey, M. S. and Flynn, I. T. W. (2020). The spatial and spectral resolution of ASTER infrared image data: A paradigm shift in volcanological remote sensing. *Remote Sensing*, 12(4):738.

Rowan, L. C. and Mars, J. C. (2003). Lithologic mapping in the Mountain Pass, California area using ASTER data. *Remote Sensing of Environment*, 84(3):350–366.

Sabins, F. F. (1999). Remote sensing for mineral exploration. *Ore Geology Reviews*, 14(3-4):157–183.

Sandler, M. et al. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4510–4520.

Shirmard, H. et al. (2022). A review of machine learning in processing remote sensing data for mineral exploration. *Remote Sensing of Environment*, 268:112750.

Song, Y. et al. (2024). Predicting rare earth elements concentration in coal ashes with multi-task neural networks. *Materials Horizons*, 11:747–757.

United States Geological Survey (2025). Interior department releases final 2025 list of critical minerals.

van der Meer, F. D. et al. (2012). Multi- and hyperspectral geologic remote sensing: A review. *International Journal of Applied Earth Observation and Geoinformation*, 14(1):112–128.

Zhu, X. X. et al. (2017). Deep learning in remote sensing: A comprehensive review and list of resources. *IEEE Geoscience and Remote Sensing Magazine*, 5(4):8–36.