SpectraAI: Prospecção de Terras Raras a partir de Imagens Multiespectrais ASTER com Aprendizado de Máquina e Visão Computacional

Drielly S. Farias[1], Eduardo F. Rizk[1], Giovanna F. B. Vieira[1], Larissa M. P. S. Souza[1], Lucas R. Jorge[1], Mateus B. Pereira[1], Pedro A. B. Martins[1]

[1]Instituto de Tecnologia e Liderança (Inteli)
Av. Prof. Almeida Prado, 520 – Butantã – 05508-901 – São Paulo – SP

{drielly.farias,eduardo.rizk,larissa.souza,giovanna.vieira, lucas.jorge,mateus.pereira,pedro.martins}@sou.inteli.edu.br

Abstract. *This work presents SpectraAI, a reproducible geospatial pipeline that transforms ASTER multispectral imagery into probabilistic indicators of rare earth element (REE) prospectivity. The methodology includes atmospheric filtering, spectral feature engineering, and construction of labeled 128x128x9 image chips. A comparative evaluation using MLP, CNN, and transfer learning with MobileNetV2 shows consistent improvement, with the final model achieving 88.14% accuracy, 0.8511 F1-score, and 0.9167 ROC-AUC. Grad-CAM analysis indicates alignment with geologically relevant patterns.*
Keywords: *remote sensing, ASTER, rare earth elements, deep learning, mineral prospecting.*

Resumo. *Este trabalho apresenta o SpectraAI, um pipeline reprodutível que transforma imagens multiespectrais ASTER em indicadores probabilísticos de potencial prospectivo de elementos de terras raras (REE). A metodologia inclui filtragem atmosférica, engenharia de atributos espectrais e construção de chips 128x128x9 rotulados. A avaliação comparativa entre MLP, CNN e transfer learning com MobileNetV2 demonstra melhoria consistente, com o modelo final alcançando 88,14% de acurácia, F1-score de 0,8511 e ROC-AUC de 0,9167.*
Palavras-chave: *sensoriamento remoto, ASTER, elementos de terras raras, aprendizado profundo, prospecção mineral.*

1. Introdução

Os Elementos de Terras Raras (Rare Earth Elements — REE) compõem um grupo de 17 elementos amplamente empregados em tecnologias de alto valor agregado, incluindo eletrônica, aplicações industriais avançadas e sistemas energéticos de baixo carbono. A demanda crescente por esses elementos, impulsionada pela transição energética global, tem intensificado preocupações quanto à segurança de suprimento, dado que a produção e o refino permanecem geograficamente concentrados [International Energy Agency 2021, United States Geological Survey 2025]. Nesse cenário, o Brasil ocupa posição estratégica em virtude de suas reservas expressivas de REE, o que reforça a relevância de métodos eficientes e escaláveis de prospecção mineral. Do ponto de vista operacional, a prospecção mineral tradicional depende de campanhas de campo, amostragem e análises laboratoriais, etapas onerosas e de difícil escalabilidade espacial. Em contrapartida, o sensoriamento remoto oferece um meio de observação sistemática e repetível para apoiar a triagem de alvos, especialmente quando combinado a métodos quantitativos de análise de dados

[Sabins 1999, van der Meer et al. 2012].

Nesse contexto, o Advanced Spaceborne Thermal Emission and Reflection Radiometer (ASTER) consolidou-se como um dos sensores mais utilizados em mapeamento litológico e exploração mineral, ao disponibilizar bandas espectrais relevantes no VNIR e no SWIR [Abrams and Yamaguchi 2019, Ramsey and Flynn 2020]. Contudo, a interpretação manual dessas cenas permanece limitada pela alta dimensionalidade espectral e pela sutileza de padrões associados a mineralizações [Shirmard et al. 2022]. Historicamente, as aplicações de aprendizado de máquina nesse domínio têm sido conduzidas a partir de representações tabulares, descartando a estrutura espacial das imagens. Para superar essa limitação, redes neurais convolucionais (CNN) permitem aprender padrões espaciais e espectrais diretamente a partir de janelas de imagem, preservando relações de vizinhança entre pixels [Zhu et al. 2017].

Este trabalho apresenta o SpectraAI, um pipeline de ciência de dados geoespaciais que utiliza imagens ASTER e dados de referência fornecidos pela Frontera Minerals para estimar, de forma probabilística, o potencial prospectivo de REE e produzir um ranking de áreas prioritárias para campanhas de pesquisa geológica de campo. As principais contribuições incluem: a construção de um pipeline reprodutível end-to-end; a comparação sistemática entre modelos tabulares (MLP), CNN e transfer learning com MobileNetV2 [Sandler et al. 2018]; e a análise de interpretabilidade via Grad-CAM.

Especificamente, o trabalho visa:

- **Construir protocolo de engenharia de atributos espectrais** para realce de minerais de alteração hidrotermal a partir de bandas ASTER;
- **Comparar arquiteturas de visão computacional** (CNN) com baselines clássicos (SVM, RF, Regressão Logística) e tabular (MLP);
- **Implementar validação estratificada** com métricas robustas ao desbalanceamento (F1-score, acurácia balanceada, ROC-AUC);
- **Produzir ranking probabilístico** de áreas prospectivas como ferramenta de apoio à decisão em exploração geológica.

2. Fundamentação Teórica

A análise por sensoriamento remoto em geociências fundamenta-se na interação entre radiação eletromagnética e materiais geológicos, em que minerais e rochas exibem respostas espectrais condicionadas por composição e estrutura físico-química. Técnicas clássicas incluem razões de bandas e Análise de Componentes Principais (PCA), frequentemente empregadas para realçar assinaturas diagnósticas de minerais de alteração e discriminar unidades litológicas [Abrams and Yamaguchi 2019, Rowan and Mars 2003]. O sensor ASTER, projetado com subsistemas em VNIR (3 canais, 15 m) e SWIR (6 canais, 30 m), favorece a investigação de características mineralógicas relevantes, tendo contribuído significativamente para mapeamento litológico e exploração mineral ao longo de décadas [Abrams and Yamaguchi 2019, Ramsey and Flynn 2020].

Nos últimos anos, a integração de aprendizado de máquina ampliou o escopo do sensoriamento remoto aplicado à exploração mineral, ao permitir modelar relações não lineares e reduzir a dependência de regras fixas. Pipeli-

nes supervisionados capazes de transformar atributos espectrais em classificações quantitativas têm sido propostos, comparando algoritmos clássicos e redes neurais [Bahrami et al. 2024]. Revisões sobre *mineral prospectivity mapping* com *deep learning* destacam desafios como escassez de rótulos, desbalanceamento de classes e generalização espacial (SUN et al., 2024; SHIRMARD et al., 2022).

3. Materiais e Métodos

3.1. Materiais

Os materiais utilizados reúnem dados orbitais, dados de referência geográfica e metadados de rotulagem fornecidos pela Frontera Minerals. A base orbital é composta por cenas ASTER do produto L2 Surface Reflectance VNIR and Crosstalk-Corrected SWIR (AST_07XT) [NASA], com janela temporal entre 2000 e 2007 para preservar a disponibilidade operacional das bandas SWIR. Foram priorizadas as bandas VNIR (B01, B02, B03N) e SWIR (B04-B09), totalizando nove bandas por chip. As cenas candidatas são recuperadas por caixa geográfica ao redor dos pontos-alvo, com seleção por menor cobertura de nuvens. O material de referência para supervisão é composto por coordenadas georreferenciadas de interesse geológico e listas de códigos positivos e negativos. Após a remoção de amostras com rótulos inválidos, o dataset final contém 295 chips multiespectrais, dos quais 179 pertencem à classe negativa (60,7%) e 116 à classe positiva (39,3%).

3.2. Métodos

3.2.1. Aquisição e Pré-processamento

A base de dados é composta por amostras de solo e rocha coletadas *in situ* pela Frontera Minerals, rotuladas binariamente: classe positiva (áreas com teores acima do *cut-off* econômico) e classe negativa (áreas estéreis ou com teores de base). As assinaturas espectrais foram extraídas de imagens ASTER, priorizando cenas históricas (2000-2007) com cobertura de nuvens inferior a 20% [NASA]. O pré-processamento incluiu filtragem de máscaras (remoção de pixels contaminados por nuvens e vegetação densa), reprojeção para WGS84, cálculo de índices minerais baseados em razões de bandas (como o Índice de Argilas, B06/(B05+B04)) e vetorização para a fase inicial de baselines. O dataset é construído a partir de chips gerados ao redor de pontos georreferenciados, sendo cada chip um GeoTIFF multibanda (128×128×9) com bandas VNIR+SWIR alinhadas. A extração utiliza *bounding box* com jitter controlado por semente, garantindo variação posicional do ponto de referência dentro do chip.

3.2.2. Modelagem

O desempenho de referência foi estabelecido por algoritmos clássicos (SVM, Random Forest, Regressão Logística) otimizados via *GridSearchCV* e por uma rede neural densa (MLP) como baseline de deep learning sobre dados vetorizados. Visando superar a limitação da MLP, que ignora a vizinhança espacial, o projeto evoluiu para redes neurais convolucionais (CNN), que recebem o chip em sua forma original (altura × largura × canais), permitindo que filtros convolucionais identifiquem texturas e padrões morfológicos. A arquitetura baseline é composta por dois blocos convolucionais (Conv2D com ReLU, regularização L2 e MaxPooling2D) seguidos por camadas densas de classificação com ativação sigmoid. Para investigar o impacto de escolhas arquiteturais, foram definidas seis configurações em estudo de ablação, variando taxas de dropout, learning rate, profundidade da rede e resolução de entrada.

3.2.3. Protocolo Experimental

O dataset foi dividido em treinamento (70%), validação (15%) e teste (15%), utilizando amostragem estratificada em duas etapas com a função *train_test_split* do scikit-learn. Essa divisão assegura que a proporção entre classes seja preservada em todos os subconjuntos. A normalização é realizada por padronização z-score por canal espectral, cujos parâmetros são estimados exclusivamente a partir do conjunto de treinamento e aplicados aos conjuntos de validação e teste, evitando vazamento de informação estatística. O conjunto de validação monitora o desempenho ao longo das épocas e identifica sinais de sobreajuste, enquanto o conjunto de teste permanece isolado até a avaliação final. O desempenho é avaliado por F1-score, acurácia balanceada e ROC-AUC, métricas adequadas para cenários com desbalanceamento de classes. Data augmentation (RandomFlip, RandomRotation e RandomContrast) é aplicada exclusivamente ao conjunto de treinamento.

3.2.4. Transfer Learning

Reconhecendo o tamanho limitado do dataset (N=295), o pipeline incorporou transfer learning com o backbone MobileNetV2 [Sandler et al. 2018], pré-treinado no ImageNet. Para compatibilizar as 9 bandas ASTER com os 3 canais esperados pelo modelo, uma camada de convolução 1×1 realiza combinação linear das bandas para projeção em espaço latente de 3 canais, preservando a riqueza espectral com apenas ˜30 parâmetros adicionais. O treinamento ocorre em duas fases: na primeira (head training, 4 épocas), o backbone permanece congelado e apenas a camada adaptadora e a cabeça de classificação são treinadas; na segunda (fine-tuning parcial, 8 épocas), as últimas 20 camadas do MobileNetV2 são desbloqueadas (exceto BatchNormalization). Grid search sobre learning rates {1e-4, 1e-5} e batch sizes {8, 32} identificou a configuração ótima (LR=1e-4, BS=8).

4. Trabalhos Relacionados

Abrams e Yamaguchi [Abrams and Yamaguchi 2019] documentam duas décadas de contribuições do sensor ASTER para mapeamento litológico e exploração mineral, consolidando práticas de razões de bandas e PCA como ferramentas de extração de informação mineralógica. O estudo destaca a configuração espectral do sensor, com seis bandas SWIR e cinco bandas TIR, como determinante para distinguir minerais de alteração hidrotermal (argilas, carbonatos, sulfatos), além de relatar o uso crescente de redes neurais para classificação litológica. Nesse contexto, Rowan e Mars [Rowan and Mars 2003] foram os primeiros a demonstrar a capacidade das 14 bandas ASTER em distinguir litologias e mapear zonas de contato metamórfico associadas a depósitos de REE em Mountain Pass (Califórnia), validando empiricamente a viabilidade dos dados multiespectrais para caracterização mineral em condições de boa exposição superficial.

Bahrami et al. [Bahrami et al. 2024] investigam mapeamento litológico automatizado com ASTER na região de Sar-Cheshmeh (Irã), comparando RF, SVM, XGBoost e ANN e evidenciando que escolhas de pré-processamento e seleção de atributos espectrais afetam significativamente a qualidade dos resultados, oferecendo um baseline metodológico sólido para comparação entre modelos clássicos e redes neurais. Entretanto, o estudo é orientado a classes litológicas regionais, não sendo desenhado para ranking prospectivo binário nem para

generalização a rótulos derivados de coordenadas georreferenciadas. Luo et al. [Luo et al. 2025] propuseram o framework DEEP-SEAM v1.0 com Deviation Networks para prospecção semi-supervisionada em dados multi-fonte, alcançando bom desempenho em cenários com rótulos escassos, mas sem utilizar sensoriamento remoto multiespectral nativo como fonte primária de evidências. Song et al. [Song et al. 2024] aplicaram redes multitarefa a dados geoquímicos tabulares para predição de concentração de REE em cinzas de carvão, demonstrando capacidade de filtrar ruído e capturar correlações não lineares, porém sem explorar informação de imagem ou estrutura espacial. Chen et al. [Chen et al. 2014] foram pioneiros em aplicar deep learning com patches espaciais a dados hiperespectrais de sensoriamento remoto, demonstrando ganhos expressivos sobre SVM em abordagem análoga à estratégia de chips do SpectraAI, mas voltada a classificação de uso do solo e não a prospecção mineral com desbalanceamento de classes e rótulos de referência geológica. Shirmard et al. [Shirmard et al. 2022] reforçam que poucos estudos comparam representações tabulares e espaciais sistematicamente sobre o mesmo dataset, lacuna diretamente endereçada pelo pipeline proposto.

5. Resultados e Discussão

5.1. Comparação de Desempenho

A avaliação sistemática do pipeline proposto abrangeu três arquiteturas complementares: modelos tabulares supervisionados, tendo a rede neural densa (MLP) como referência, redes neurais convolucionais (CNN) treinadas do zero e transfer learning com MobileNetV2 pré-treinada. A comparação foi conduzida sob condições experimentais idênticas, utilizando o mesmo dataset (N=295, 70% treinamento, 15% validação, 15% teste estratificado) e métricas robustas ao desbalanceamento de classes. O modelo MLP, operando sobre representação tabular com PCA em 2 componentes, alcançou acurácia de 79,66% e F1-score de 0,7391, estabelecendo o baseline de referência. O desempenho limitado reflete a perda de informação espacial decorrente da compressão por PCA, que impede a captura de padrões morfológicos e contextuais associados a mineralizações.

A CNN baseline, ao preservar a estrutura espacial dos chips (128×128×9), elevou o desempenho para 82,44% de acurácia e ROC-AUC de 0,9011 na melhor configuração de ablação (64×64), confirmando que a informação espacial é relevante para o problema. O estudo de ablação identificou que a redução de resolução de entrada melhorou a generalização ao reduzir dimensionalidade enquanto preserva informação discriminativa, e que a remoção de camadas convolucionais causa colapso em ROC-AUC (de 0,9011 para 0,7083), confirmando a essencialidade da extração automática de características espaciais. O transfer learning com MobileNetV2, aproveitando representações pré-aprendidas no ImageNet com adaptação espectral via convolução 1×1, alcançou resultados superiores em todas as métricas: acurácia de 84,75%, F1-score de 0,8085 e ROC-AUC de 0,9312, com convergência em apenas 12 épocas e redução de 72% em parâmetros treináveis em relação à CNN simples, confirmando a viabilidade do transfer learning em cenários com dados limitados. A progressão completa de desempenho de A03 a A11 é detalhada na Seção 5.2.

5.2. Modelo Final (Pipeline A11)

O pipeline final (A11) foi executado de forma integrada e reprodutível (seed=42), com treinamento em duas fases do MobileNetV2 adaptado espectralmente, sobre o dataset completo de 295 chips multiespectrais ASTER (177 treino, 59 validação, 59 teste). O modelo final alcançou acurácia de 88,14%, F1-score de 0,8511 e ROC-AUC de 0,9167 (Tabela 1), convergindo em 13 épocas (6 head + 7 fine-tuning) e 94,4 s de treinamento.

Tabela 1. Métricas do modelo final (A11) no conjunto de teste. Fonte: Autores (2026)

Métrica	Valor
Acurácia	88,14%
Precisão	83,33%
Recall (Sensibilidade)	86,96%
F1-score	0,8511
Acurácia Balanceada	87,92%
ROC-AUC	0,9167
PR-AUC	0,8588
Épocas totais	13 (6 head + 7 fine-tuning)
Tempo de treinamento	94,4 s

A Figura 1 apresenta a matriz de confusão do modelo final no conjunto de teste (n=59). O modelo classificou corretamente 52 das 59 amostras (88,14%), com TN=32, FP=4, FN=3 e TP=20. A redução de falsos positivos (de 5 para 4) e falsos negativos (de 4 para 3) em relação ao A08 confirma a melhoria de generalização do pipeline consolidado. O recall de 86,96% indica que o modelo detecta a grande maioria das áreas com potencial de REE, enquanto a precisão de 83,33% assegura que a maioria das áreas sinalizadas corresponde a regiões de interesse geológico. A Figura 2 apresenta as curvas ROC (AUC=0,92) e Precision-Recall (AP=0,86), demonstrando capacidade discriminativa robusta em diferentes limiares de decisão e manutenção de alta precisão mesmo em regimes de alto recall. Do ponto de vista operacional, os escores probabilísticos produzidos pelo modelo permitem ordenar as áreas analisadas em um ranking contínuo de prospectividade, no qual regiões com maior probabilidade de presença de REE são priorizadas para investigação de campo, constituindo o produto final do pipeline como ferramenta de apoio à decisão em exploração mineral.

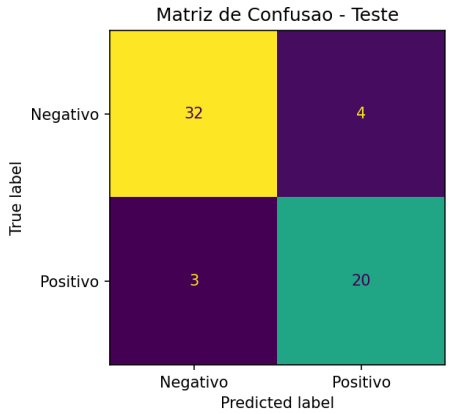

Figura 1. Matriz de Confusão do Modelo Final (A11) — Conjunto de Teste. Fonte: Autores (2026)

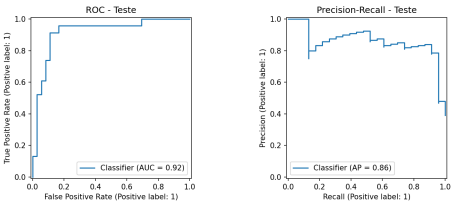

Figura 2. Curvas ROC e Precision-Recall do Modelo Final (A11). Fonte: Autores (2026)

5.3. Interpretabilidade via Grad-CAM

A Figura 3 apresenta mapas de ativação Grad-CAM que visualizam quais regiões espaciais o modelo MobileNetV2 prioriza ao fazer predições. A visualização sobrepõe os mapas de calor a um chip ASTER em falsa cor de uma amostra da classe positiva, comparando as ativações para as predições de cada classe. O mapa da classe positiva (real) revela ativações concentradas em transições espectrais coerentes e bordas espaciais pronunciadas, enquanto o mapa da classe negativa apresenta padrão mais disperso e difuso. Essa concentração alinha-se com o conhecimento geológico de que bandas SWIR são sensíveis a óxidos e argilas associados a REE, e que limites de

alteração constituem estruturas espaciais informativas. A diferença de padrão entre as predições de classes positiva e negativa sugere que a rede responde a combinações espaciais e espectrais relevantes, conferindo transparência às predições e facilitando a auditoria por especialistas de domínio.

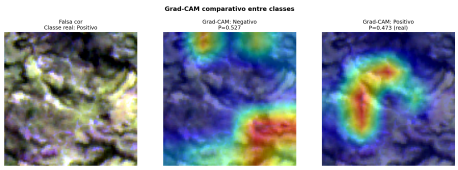

Figura 3. Mapas Grad-CAM do Modelo Final — Comparação entre Classes. Fonte: Autores (2026)

5.4. Discussão

A superioridade do transfer learning valida a hipótese de que informação espacial via CNN, combinada com representações pré-aprendidas no ImageNet, oferece vantagens significativas para identificação de padrões associados a REE. O estudo de ablação reforça essa conclusão: regularização L2 e dropout controlam a complexidade do modelo, enquanto a remoção de camadas convolucionais causa colapso em ROC-AUC. A assimetria de custos entre os tipos de erro é relevante nesse contexto: falsos negativos representam oportunidades de prospecção perdidas, enquanto falsos positivos implicam esforço de campo desperdiçado, o que justifica o uso conjunto de ROC-AUC e PR-AUC como métricas de avaliação. Apesar dos resultados encorajadores, o dataset de 295 amostras situa-se no limiar inferior de viabilidade para deep learning, e a validação utilizou rótulos de referência sem confirmação de campo. Ainda assim, o pipeline demonstra o potencial do aprendizado profundo aplicado a sensoriamento remoto como ferramenta de apoio à prospecção mineral.

6. Conclusão

O SpectraAI demonstrou ser um pipeline reprodutível e eficaz para prospecção de REE a partir de imagens ASTER, cujo produto final é um ranking probabilístico de áreas por potencial prospectivo. Os experimentos evidenciaram progressão consistente de desempenho — do MLP (79,66%) à CNN (82,44%) ao pipeline final A11 com transfer learning (88,14% de acurácia, F1=0,8511, ROC-AUC=0,9167) — com redução progressiva de erros concretos: de 6 FP e 6 FN no MLP para 4 FP e 3 FN no modelo final, evidenciando ganho operacional direto em cada etapa.

6.1. Principais Contribuições

As contribuições do trabalho são: **(i)** a construção de um pipeline reprodutível end-to-end, desde a aquisição de cenas ASTER até a exportação de predições, com controle de seed e separação rigorosa entre conjuntos de dados; **(ii)** a comparação sistemática e controlada entre MLP, CNN e transfer learning sob métricas robustas ao desbalanceamento; **(iii)** a demonstração de que transfer learning com adaptação espectral via convolução 1×1 é viável e eficaz com poucos dados rotulados (N=295); e **(iv)** a análise de interpretabilidade via Grad-CAM, que revelou alinhamento entre regiões ativadas e características espectrais geologicamente relevantes, conferindo transparência às predições. Do ponto de vista prático, o ranking probabilístico de áreas produzido pelo pipeline representa uma ferramenta concreta de apoio à decisão em exploração mineral, capaz de reduzir custos operacionais ao direcionar esforços de campo para regiões com maior probabilidade de ocorrência de REE.

6.2. Limitações e Trabalhos Futuros

Limitações relevantes incluem: o dataset de 295 amostras situa-se no limiar inferior de viabilidade para deep learning; os rótulos derivam de referência geológica sem validação de campo; e a amostragem estratificada aleatória não garante generalização espacial. Como direções futuras, destacam-se validação geológica in situ, validação cruzada espacial, integração multissensor (Landsat-8, Sentinel-2) e investigação de arquiteturas avançadas (ResNet, Transformers).

Referências

Abrams, M. and Yamaguchi, Y. (2019). Twenty years of ASTER contributions to lithologic mapping and mineral exploration. *Remote Sensing*, 11(11):1394.

Bahrami, H. et al. (2024). Machine learning-based lithological mapping from ASTER remote-sensing imagery. *Minerals*, 14(2):202.

Chen, Y. et al. (2014). Deep learning-based classification of hyperspectral data. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 7(6):2094–2107.

International Energy Agency (2021). The role of critical minerals in clean energy transitions. Technical report, IEA, Paris.

Luo, Z. et al. (2025). An explainable semi-supervised deep learning framework for mineral prospectivity mapping: DEEPSEAM v1.0. *EGUsphere (preprint)*.

NASA. ASTER L2 surface reflectance VNIR and crosstalk-corrected SWIR (AST_07XT). NASA Earthdata. Acesso em: 26 fev. 2026.

Ramsey, M. S. and Flynn, I. T. W. (2020). The spatial and spectral resolution of ASTER infrared image data: A paradigm shift in volcanological remote sensing. *Remote Sensing*, 12(4):738.

Rowan, L. C. and Mars, J. C. (2003). Lithologic mapping in the Mountain Pass, California area using ASTER data. *Remote Sensing of Environment*, 84(3):350–366.

Sabins, F. F. (1999). Remote sensing for mineral exploration. *Ore Geology Reviews*, 14(3-4):157–183.

Sandler, M. et al. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4510–4520.

Shirmard, H. et al. (2022). A review of machine learning in processing remote sensing data for mineral exploration. *Remote Sensing of Environment*, 268:112750.

Song, Y. et al. (2024). Predicting rare earth elements concentration in coal ashes with multi-task neural networks. *Materials Horizons*, 11:747–757.

United States Geological Survey (2025). Interior department releases final 2025 list of critical minerals.

van der Meer, F. D. et al. (2012). Multi- and hyperspectral geologic remote sensing: A review. *International Journal of Applied Earth Observation and Geoinformation*, 14(1):112–128.

Zhu, X. X. et al. (2017). Deep learning in remote sensing: A comprehensive review and list of resources. *IEEE Geoscience and Remote Sensing Magazine*, 5(4):8–36.