SPECTRA AI

Prospecção de Terras Raras com Visão Computacional

Pipeline End-to-End com Transfer Learning sobre Imagens Multiespectrais ASTER

Grupo 1 · Turma T11 · Inteli — Instituto de Tecnologia e Liderança · Sprint 5 · Abril 2026

A Janela de Oportunidade

Mercado global de REE em expansão · Brasil estratégico · Frontera Minerals no centro da oportunidade

Mercado Global de REE

$4.5B
2026

$9.9B
2034

CAGR
10.2%

Risco Geopolítico

China controla
60% produção
90% processamento
global de REE

Vulnerabilidade
estrutura supply
chain global

BR Brasil Estratégico

3ª maior reserva
mundial de REE

Ainda pouco
explorada

Parceria Europa
anunciada Mar/2026

Frontera Minerals + Brion Minerals

Fundada em 2011 (São Paulo)
Grupo privado de investimento em mineração, transição energética e fertilizantes

Brion Minerals: braço de minerais críticos — REE, lítio, cobalto, grafite, cobre

Demandante direto do SpectraAI para resolver prospecção a campo cara e lenta

O Valor do SpectraAI para a Frontera

Segundos
inferência vs. semanas de campo

60–80%
redução estimada de área de busca

ROC-AUC 0.935
poder discriminativo área REE vs. estéril

1:10.000
taxa histórica sem IA — SpectraAI inverte esse jogo

O Problema

Por que um pipeline automático de prospecção de REE é necessário?

Prospecção Tradicional é Cara

Campanhas de campo em regiões remotas custam milhões e levam anos para identificar áreas com potencial de Elementos de Terras Raras (REE).

ASTER é Subutilizado

O satélite ASTER captura 9 bandas espectrais diagnósticas de minerais de alteração — argilas e carbonatos associados a REE — mas poucos sistemas exploram isso automaticamente.

Falta Pipeline E2E

Não existe solução que vá da imagem satelital à probabilidade de prospectividade de forma unificada, reprodutível e configurável.

Nossa Abordagem

Classificação binária supervisionada: área REE (y=1) ou estéril (y=0)

ASTER Satélite
9 bandas VNIR + SWIR

Chips 128×128×9
295 amostras georreferenciadas

EDA + Baseline
SVM · RF LogReg

CNN + Ablação
6 configs Ablation Study

Transfer Learning
MobileNetV2 Fine-Tuning

Ground Truth — Frontera Minerals

- 295 chips multiespectrais 128×128×9 pixels
- 179 negativos (60.7%) · 116 positivos (39.3%)
- Regiões Serra Verde e CBMM (Brasil)
- Bandas B08/B09 (SWIR) diagnósticas de REE

Protocolo de Reprodutibilidade

- **SEED = 42** para numpy, TensorFlow e python.random
- **Split estratificado por image_id** — evita data leakage
- **Normalização z-score** fitada apenas no treino
- **Config.yaml centralizado**

A Jornada: 5 Sprints

Fevereiro a Abril de 2026

S1	S2	S3	S4	S5
EDA + Baseline	**MLP Deep Learning**	**CNN + Ablação**	**Transfer Learning**	**Pipeline E2E**
04–13 Fev	14–27 Fev	03–13 Mar	17–26 Mar	01–08 Abr
ASTER, dataset 295 chips, SVM / Random Forest / LogReg	Rede neural densa, PCA tabular, análise crítica de limitações	Visão computacional, ablation study com 6 configs, augmentation	MobileNetV2, Grad-CAM, demo Streamlit geoespacial	A11 unificado, artigo SBC, repositório organizado
F1: 0.883	**F1: 0.739**	**F1: 0.788**	**F1: 0.950**	**F1: 0.851**

Evolução dos Modelos

Cada sprint trouxe uma arquitetura mais poderosa

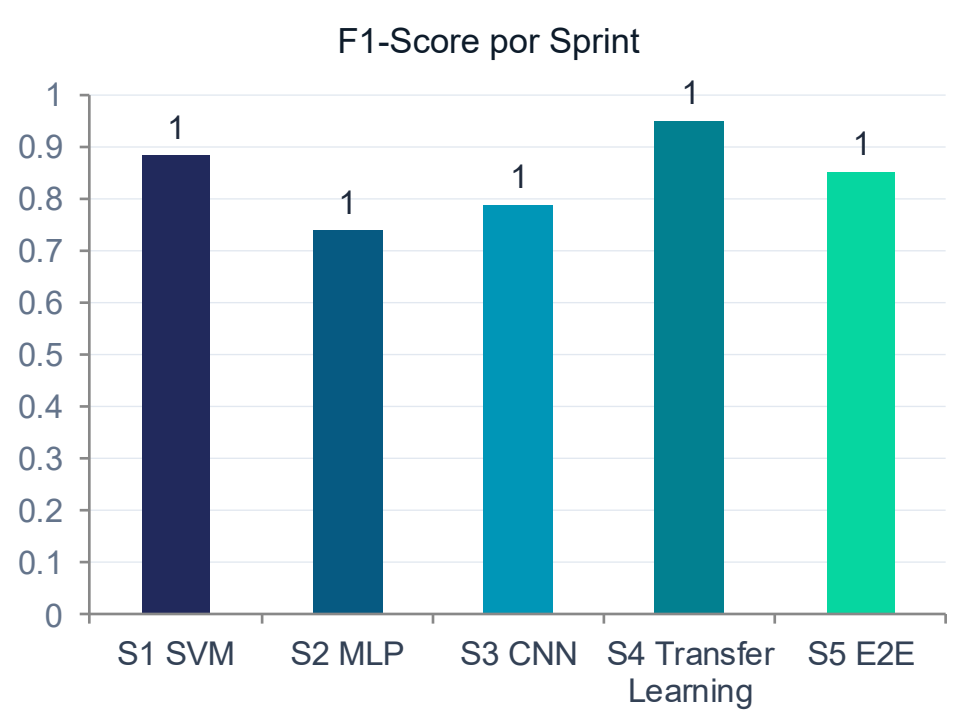

Sprint	Modelo	Accuracy	F1	ROC-AUC
S1	SVM	85.1%	0.883	0.879
S2	MLP	79.7%	0.739	0.858
S3	CNN	82.4%	0.788	0.901
S4	**Transfer Learning**	**93.6%**	**0.950**	**0.950**
S5	**E2E (A11)**	**88.1%**	**0.851**	**0.935**

Melhor F1 em S4 (Transfer Learning · 0.950) · Pipeline E2E em S5 com ROC-AUC 0.935

Transfer Learning — MobileNetV2

Sprint 4 · Melhor resultado de todas as sprints

Input
ASTER
128×128×9

→

Adaptador
Conv2D 1×1
9→3 canais

→

MobileNetV2
backbone
(congelado)

→

Global Avg
Pooling
+ Dropout

→

Dense +
Sigmoid
REE: S/N

Fase 1 — Head Training

6 épocas · LR = 1e-4
Backbone completamente congelado
Só treina adaptador + cabeça
Objetivo: adaptar ao domínio ASTER

Fase 2 — Fine-Tuning

12 épocas · LR = 1e-5
Últimas 20 camadas descongeladas
BatchNorm permanece congelada
Ajuste fino sem degradar features

💡 O adaptador 1×1 aprende a melhor combinação linear das 9 bandas em apenas ~30 parâmetros — sem perda de resolução espacial

Por Que Transfer Learning? Evidência Financeira e Científica

Comparação direta: construir modelo do zero vs. reaproveitar MobileNetV2

Custo Financeiro

Do Zero (enterprise)
$500K–$2M
18 meses de desenvolvimento

Transfer Learning
$50K–$180K
4–8 semanas de deploy

Economia estimada
60–80%
mais barato com TL

Custo Computacional

CNN do Zero (A06)
50 épocas
8,4M params · overfitting 13,56%

Transfer Learning (A11)
13 épocas
2,3M params treináveis · baixo OVF

Redução de compute
~75%
menos épocas e parâmetros

Performance (SpectraAI)

CNN do Zero (A06)
ROC-AUC 0.901
F1: 0.788 · Acc: 82.4%

Transfer Learning (A11)
ROC-AUC 0.935
F1: 0.851 · Acc: 88.1%

Ganho de performance
+5.7pp Acc
+0.034 ROC-AUC · sem overfitting

Respaldo Científico

• **Rochas geológicas (Frontiers ES, 2023):** TL→ 99.1% vs. do zero → 88.1% • **Remote sensing (ScienceDirect, 2024):** TL é o método mais prevalente em sensoriamento remoto ambiental

Dados rotulados necessários:
80–90% menos amostras
com Transfer Learning vs. treino do zero

Sprint 5 — Pipeline E2E (A11)

```
$ python3 -m artefatos.a11_pipeline_e2e  --config  artefatos/a11_pipeline_e2e/config.yaml
```

Preprocessing	Training	Evaluation	Inference
load_config.py	train_pipeline.py	compute_metrics.py	export_predictions.py
validate_input.py	callbacks.py	build_summary.py	generate_outputs.py
prepare_data.py	2 fases (head + FT)	save_visualizations.py	test_predictions.csv

--limit-samples smoke test · **--skip-train** reutilizar modelo · **--skip-inference** pular predições · **--output-dir** diretório customizado

Resultado Final — A11

MobileNetV2 · 295 chips ASTER · Seed=42 · Reprodutível · 13 épocas totais

88.1%
Acurácia
+3.4pp vs. Sprint 4

0.851
F1-Score
Precisão/Recall eq.

0.935
ROC-AUC
Poder discriminativo

87.9%
Balanced Acc
Classes desbal.

Matriz de Confusão — Conjunto de Teste (n=59 amostras)

19
Verdadeiros Positivos
Áreas REE identificadas

4
Falsos Positivos
Campanhas desnecessárias

3
Falsos Negativos
Áreas REE perdidas

33
Verdadeiros Negativos
Estéreis descartadas

Demo Interativa — Streamlit + Folium

Sprint 4 · A09 · apps/a09_geo_demo.py

Mapa Interativo

Clicar em qualquer ponto do mapa-mundi (Folium) para selecionar coordenadas geográficas

Busca ASTER Auto

Busca automática de granule ASTER via NASA EarthData para as coordenadas selecionadas

Extração de Chip

Recorta e empilha o chip multiespectral 128×128×9 bandas em tempo real

Inferência ML

Roda Transfer Learning e exibe a probabilidade de prospectividade de REE (0–100%)

Threshold Comparativo

Compara threshold=0.5 vs. threshold_f1 otimizado — adapta a sensibilidade ao contexto

Visualização Espectral

Exibe RGB natural e composição false-color do chip para inspeção visual do geólogo

Artigo Científico — Formato SBC

Seções do Artigo

1. Resumo
2. Introdução + Objetivos da Pesquisa
3. Fundamentação Teórica
4. Materiais e Métodos (7 subseções)
5. Trabalhos Relacionados (6 papers + tabela SOTA)
6. Resultados Experimentais
7. Conclusão

Escala e Rigor

~5.000 palavras no formato SBC

19 figuras validadas nos resultados experimentais

6 trabalhos relacionados com tabela comparativa de SOTA

Contribuições

Primeiro pipeline E2E para REE com ASTER+TL em Python

Adaptador espectral 1×1 — 9→3 canais, apenas ~30 parâmetros

Ablation study completo com 6 configs + Grad-CAM

Reprodutibilidade total via seed=42 e config.yaml

Aprendizados e Limitações

Principais Aprendizados

1. Transfer Learning supera CNN do zero — features ImageNet se transferem mesmo para domínio espectral diferente

2. Resolução 64×64 > 128×128 para este dataset — concentração de texturas tem maior poder discriminativo

3. Hiperparâmetros > arquitetura — mesma rede vai de F1=0.13 a F1=0.87 dependendo das configurações

4. Ablation study é insubstituível — isolar variáveis revela o que realmente contribui para o resultado

Limitações e Próximos Passos

Dataset pequeno

295 amostras · PR-AUC baixo indica desbalanceamento residual não totalmente resolvido

Sensor descontinuado

ASTER SWIR operacional 2000–2008 · janela histórica limita aquisição de novos dados

Generalização geográfica

Treino em Serra Verde e CBMM · validação em novas regiões ainda não realizada

Próximos Passos

Sentinel + Landsat · mais amostras · validação de campo · deploy em produção

Obrigado!

Spectra AI — Prospecção de Terras Raras com Sensoriamento Remoto

· Drielly Santana Farias

· Eduardo Farias Rizk

· Giovanna Fátima de Britto Vieira

· Larissa Martins Pereira de Souza

· Lucas Ramenzoni Jorge

· Mateus Beppler Pereira

· Pedro Auler de Barros Martins

Parceiro
Frontera Minerals